Breast Cancer Classification Project

Informazioni Progetto

Gruppo:

- Francesco Saponara (886465)
- Mattia Chittoni (886462)

Email: f.saponara@campus.unimib.it
Consegna: Gennaio 2026

---

1. Dataset

Nome: Breast Cancer Wisconsin (Diagnostic)
Fonte: UCI Machine Learning Repository
Link: [Breast Cancer Wisconsin (Diagnostic) - UCI Machine Learning Repository]

Caratteristiche:

- **Campioni:** 569 pazienti
- **Features:** 30 caratteristiche numeriche calcolate da immagini di nuclei cellulari
- **Target:** Diagnosi (M = Malignant/Maligno, B = Benign/Benigno)
- **Distribuzione Classi:** 357 Benigni (62.7%), 212 Maligni (37.3%)

---

2. Preprocessing dei Dati

I seguenti step di preprocessing sono stati applicati:

- **Rimozione colonne:** ID e colonne unnamed eliminate
- **Gestione valori mancanti:** Valori NaN sostituiti con la mediana della colonna
- **Gestione valori zero:** Valori zero (impossibili nelle misurazioni mediche) sostituiti con la media della colonna (escludendo gli zero)
- **Encoding target:** LabelEncoder utilizzato (M=1, B=0)
- **Standardizzazione:** StandardScaler applicato a tutte le features (media=0, std=1)
- **Train-Test Split:** 70% training, 30% test, stratificato

---

3. Modelli di Classificazione

3.1 Support Vector Machine (SVM)

Configurazione Baseline:

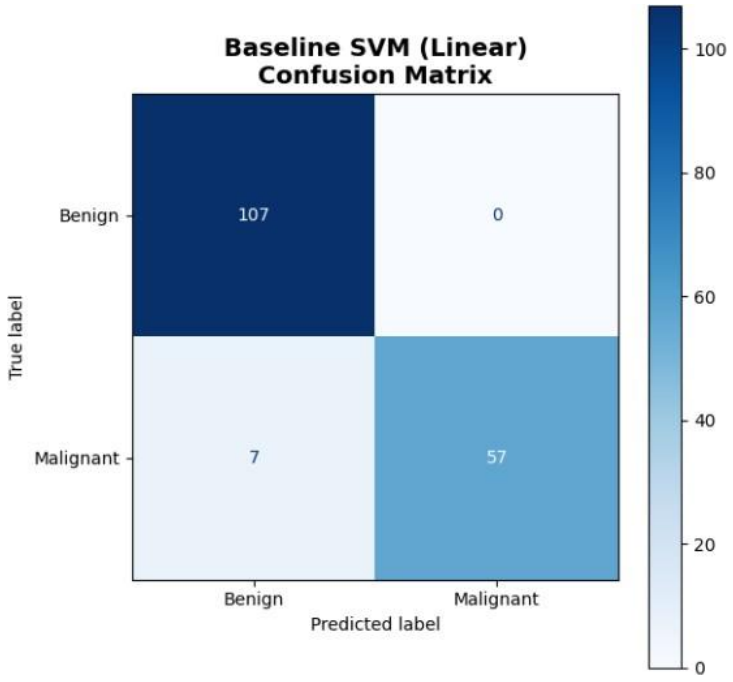
- Kernel: RBF (Radial Basis Function)
- C: 1 (default)
- Gamma: 'scale'

> **Nota:** Abbiamo provato a ottimizzare i risultati di SVM attraverso l'uso di GridSearchCV, ma i risultati di SVM Optimized non sono mostrati in quanto identici al baseline. Il modello baseline ha già utilizzato i parametri ottimali (kernel='rbf', C=1, gamma='scale'), come confermato dal GridSearchCV.

Metriche di Performance - SVM

Metrica	Valore	Formula
Accuracy	**0.9591**	(TP+TN)/Total = (57+107)/171
Precision	**1.0000**	TP/(TP+FP) = 57/(57+0)
Recall	0.8906	TP/(TP+FN) = 57/(57+7)
F1-Score	0.9421	2×(Precision×Recall)/(Precision+Recall)
ROC-AUC	**0.9971**	Area sotto la curva ROC

Confusion Matrix – SVM



Classification Report - SVM

Classe	Precision	Recall	F1-Score	Support
Benign	0.94	1.00	0.97	107
Malignant	1.00	0.89	0.94	64
Accuracy			**0.96**	**171**
Macro Avg	0.97	0.95	0.96	171
Weighted Avg	0.96	0.96	0.96	171

3.2 Neural Network (Multi-Layer Perceptron)

Baseline Configuration:

- Architecture: 2 hidden layers (32, 16 neurons)
- Activation: ReLU
- Learning Rate: 0.001
- Alpha (L2): 0.001
- Training Iterations: 23
- Training Loss: 0.1167

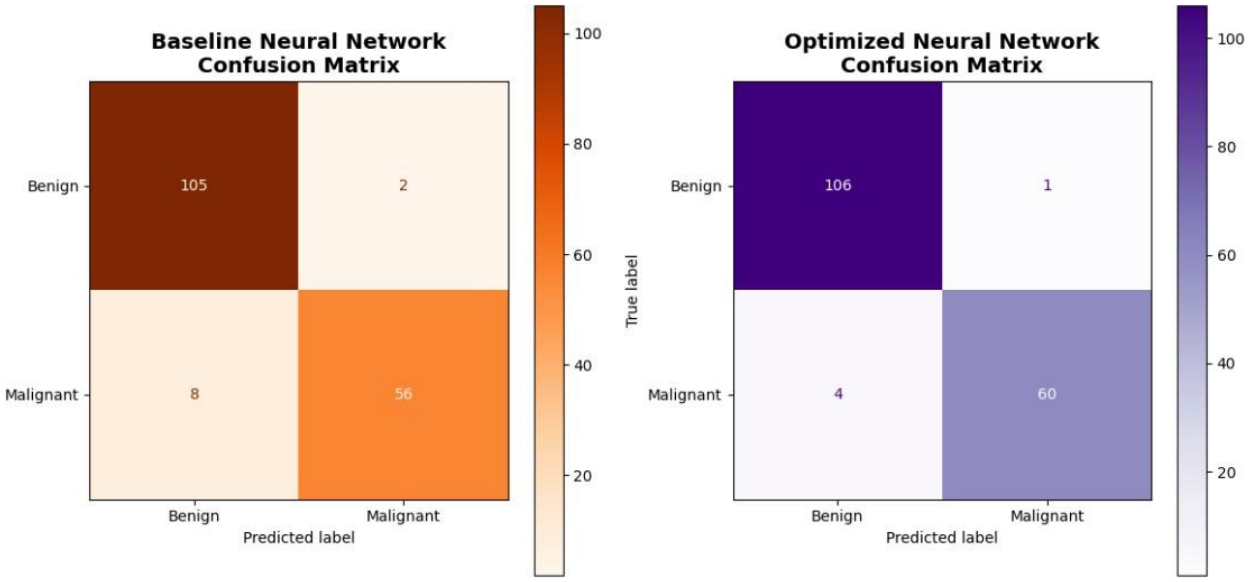
Metriche di Performance - Neural Network

Metrica	Baseline	Optimized
Accuracy	0.9415	**0.9708**
Precision	0.9655	**0.9836**
Recall	0.8750	**0.9375**
F1-Score	0.9180	**0.9600**
ROC-AUC	0.9902	**0.9982**

Optimized Configuration (GridSearchCV):

- Architecture: 1 hidden layer (64 neurons)
- Activation: Tanh
- Learning Rate: 0.01
- Alpha (L2): 0.0001
- Training Iterations: 19
- Training Loss: 0.0557
- Cross-Validation Score: 0.9698 (±0.0341)

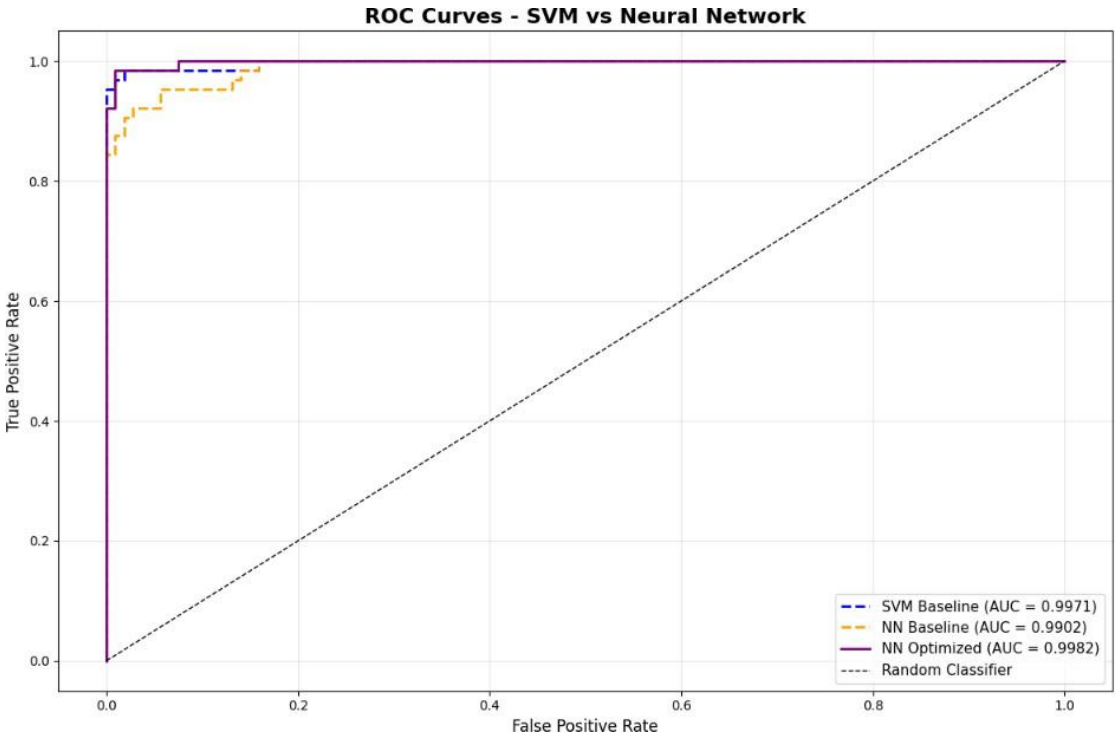
Confusion Matrix – NN



3.3 Confronto Modelli

Modello	Accuracy	Precision	Recall	F1-Score	ROC-AUC
SVM (Baseline)	0.9591	**1.0000**	0.8906	0.9421	0.9971
NN (Baseline)	0.9415	0.9655	0.8750	0.9180	0.9902
NN (Optimized)	**0.9708**	**0.9836**	**0.9375**	**0.9600**	**0.9982**

3.4 Confronto Curve ROC



Modello Migliore

Neural Network (Optimized)

Accuracy: 97.08% | ROC-AUC: 0.9982

Configurazione: 1 hidden layer (64 neurons), Activation: Tanh, Learning Rate: 0.01, L2 Regularization: 0.0001

Conclusioni Chiave

- **Performance Eccellenti:** Tutti i modelli hanno raggiunto accuracy superiore al 94%, dimostrando che il dataset è ben strutturato per la classificazione.
- **SVM - Precision Perfetta:** Il modello SVM ha ottenuto precision 1.0, significando zero falsi positivi. Questo è cruciale in ambito medico dove un falso positivo causa stress non necessario al paziente.
- **Neural Network - Migliore Bilanciamento:** La rete neurale ottimizzata ha raggiunto il miglior bilanciamento tra precision (0.9836) e recall (0.9375), con il minor numero di falsi negativi (4 vs 7 di SVM).
- **Importanza del Recall:** In diagnosi oncologica, il recall è critico perché rappresenta la capacità di identificare tutti i casi di cancro. Un falso negativo (mancata diagnosi di cancro) è più pericoloso di un falso positivo.

- **Hyperparameter Tuning Efficace:** Il GridSearchCV ha migliorato significativamente la Neural Network (+2.93% accuracy, +6.25% recall), mentre SVM era già ottimale con i parametri default.
- **PCA Insights:** La riduzione dimensionale ha mostrato una chiara separazione delle classi nello spazio ridotto, confermando che le features sono altamente discriminative.
- **Preprocessing Cruciale:** La standardizzazione e la gestione dei valori zero/NaN sono stati essenziali per le performance dei modelli, specialmente per SVM e Neural Networks.

---

4. Interpretazione Medica dei Risultati

4.1 Analisi degli Errori

SVM:

- 0 Falsi Positivi → Nessun paziente benigno classificato erroneamente come maligno
- 7 Falsi Negativi → 7 casi di cancro non rilevati (10.9% dei casi maligni)

Neural Network (Optimized):

- 1 Falso Positivo → 1 paziente benigno classificato come maligno (richiederà ulteriori test)
- 4 Falsi Negativi → 4 casi di cancro non rilevati (6.25% dei casi maligni)

4.2 Trade-off Precision vs Recall

In contesto medico oncologico:

- **SVM:** Massimizza la precision (minimizza falsi positivi) ma ha recall inferiore. Adatto quando si vuole evitare stress e costi di follow-up non necessari.
- **Neural Network:** Migliore recall (minimizza falsi negativi) con precision ancora eccellente. Preferibile quando l'obiettivo primario è non perdere casi di cancro.

---

5. Metodologia e Strumenti

5.1 Linguaggi e Librerie

- **Python 3.8+**
- **scikit-learn:** Modelli ML, preprocessing, metriche
- **pandas:** Manipolazione dati
- **numpy:** Operazioni numeriche
- **matplotlib & seaborn:** Visualizzazioni

5.2 Pipeline di Sviluppo

1. Exploratory Data Analysis (EDA)
2. Data Cleaning e Preprocessing
3. Feature Scaling
4. Model Training (Baseline)
5. Hyperparameter Tuning (GridSearchCV)
6. Model Evaluation (Cross-Validation, Test Set)
7. Results Interpretation

5.3 Validation Strategy

- **Train-Test Split:** 70-30, stratificato
- **Cross-Validation:** 5-fold per hyperparameter tuning
- **Metrics:** Accuracy, Precision, Recall, F1-Score, ROC-AUC
- **Confusion Matrix:** Analisi dettagliata degli errori

---

6. Limitazioni e Sviluppi Futuri

6.1 Limitazioni Attuali

- Dataset di dimensioni moderate (569 campioni)
- Features già pre-processate e aggregate (non immagini raw)
- Dataset sbilanciato (62.7% benign vs 37.3% malignant)
- Manca validazione su dati esterni da altri ospedali

6.2 Possibili Miglioramenti

- **Ensemble Methods:** Combinare SVM e Neural Network per sfruttare i punti di forza di entrambi
- **Deep Learning:** CNN su immagini originali dei nuclei cellulari
- **Feature Engineering:** Creazione di nuove features da interazioni
- **Class Balancing:** SMOTE o altre tecniche per bilanciare le classi
- **Threshold Optimization:** Ottimizzare la soglia di decisione per massimizzare recall